

O uso de uma métrica de cores não linear pode melhorar sistematicamente a segmentação?

Pode o uso de uma métrica de cor não linear melhorar sistematicamente a segmentação?

Carvalho, L.E.^{15*}, Mantelli Neto, S. L²⁵, Sobieranski, A.C.³⁵, Comunello, E., A.C.⁴⁵, von Wangenheim

Resumo: A segmentação de imagem é um procedimento onde uma imagem é dividida em suas partes constituintes, de acordo com algum critério. Na literatura, existem diferentes abordagens bem conhecidas para segmentação, como agrupamento, limiar, teoria gráfica e crescimento da região. Tais abordagens, além disso, podem ser combinadas com métricas de distância de cores, desempenhando um papel importante para a computação de similaridade de cores. Com o objetivo de investigar abordagens gerais capazes de melhorar o desempenho dos métodos de segmentação, este trabalho apresenta um estudo empírico do efeito de uma métrica de cor não linear nos procedimentos de segmentação. Para isso, foram escolhidos três algoritmos: Mumford-Shah, Color Structure Code e Felzenszwalb e Huttenlocher Segmentation. A métrica de similaridade de cor empregada por esses algoritmos (L2-norm) foi substituída pela Distância De Mahalanobis Polinomial. Esta métrica é uma extensão da distância estatística mahalanobis usada para medir a distância entre coordenadas e centros de distribuição. Foi realizada uma avaliação baseada na comparação automatizada dos resultados de segmentação com as verdades fundamentais do Conjunto de Dados de Berkeley. Todas as três abordagens de segmentação foram comparadas com suas implementações tradicionais, umas contra as outras e também com um grande conjunto de outros métodos de segmentação. A análise estatística realizada indicou uma melhoria sistemática dos resultados de segmentação para as três abordagens de segmentação quando a métrica não linear foi empregada.

Palavras-chave: Segmentação de imagem — Métricas de cores não lineares — Distância de Mahalanobis Polinomial — Split and Merge — Métodos Variacionais — Segmentação baseada em gráfico

Resumo: A segmentação de imagens é um procedimento onde uma imagem é dividida em suas partes constituintes, de acordo com algum critério. Na literatura, existem diferentes abordagens bem conhecidas para segmentação, como clustering, thresholding, teoria dos grafos e crescimento de regiões. Tais abordagens, adicionalmente, podem ser combinadas com métricas de distância de cores, desempenhando um papel importante para o cálculo da similaridade de cores. Com o objetivo de investigar abordagens gerais capazes de melhorar o desempenho de métodos de segmentação, este trabalho apresenta um estudo empírico do efeito de uma métrica de cor não linear em procedimentos de segmentação. Para tanto, foram escolhidos três algoritmos: Mumford-Shah, Código de Estrutura de Cores e Segmentação de Felzenszwalb e Huttenlocher. A métrica de similaridade de cores empregada por esses algoritmos (L2-norm) foi substituída pela Distância Polinomial de Mahalanobis. Esta métrica é uma extensão da distância estatística Mahalanobis usada para medir a distância entre coordenadas e centros de distribuição. Foi realizada uma avaliação baseada na comparação automatizada dos resultados da segmentação com as verdades do terreno do Berkeley Dataset. Todas as três abordagens de segmentação foram comparadas com suas implementações tradicionais, entre si e também com um grande conjunto de outros métodos de segmentação. A análise estatística realizada indicou uma melhoria sistemática dos resultados de segmentação para todas as três abordagens de segmentação quando a métrica não linear foi empregada.

Palavras-Chave: Segmentação — Métricas de cor não-linear — Distância polinomial de Mahalanobis, ^ Divisão e fusão — Métodos variacionais — Segmentação baseada em grafos

¹Programa de Graduação em Ciência da Computação - Universidade Federal de Santa Catarina, Florianópolis, Santa Catarina, Brasil

²Brazilian Institute for Space Research - INPE, São José dos Campos, São Paulo, Brasil

³Departamento de Computação - Universidade Federal de Santa Catarina, Araranguá, Brasil

⁴Universidade do Vale do Itajaí - Univali, Itajaí, Santa Catarina, Brasil

⁵Instituto Nacional de Convergência Digital - Universidade Federal de Santa Catarina, Florianópolis, Santa Catarina, Brasil

*Autor correspondente: lcarvalho@incod.ufsc.br

DOI: <https://doi.org/10.22456/2175-2745.79885> • Recebido: 23/01/2018 • Aceito: 04/08/2018

CC BY-NC-ND 4.0 - Este trabalho é licenciado sob uma Licença Internacional Creative Commons Atribuição-Não Comercial-Não Comercial-Não-Não-0.

1. Introdução

A segmentação de imagens coloridas complexas de forma rápida e confiável ainda representa um grande desafio para o campo do processamento e compreensão de imagens [1]. Existem várias abordagens de segmentação de imagens, cada uma com suas próprias vantagens e desvantagens. O principal desafio na área de segmentação é criar algoritmos

que contornem o problema de mais e sob segmentação, dividindo um único objeto em muitas regiões, vazando limites de região em outro objeto ou até mesmo fundindo vários objetos em um único. Para obter resultados que superem esses problemas, diversas abordagens têm sido propostas na literatura, melhorando ou combinando os já existentes. Um exemplo é a substituição da métrica de

similaridade de cor para alcançar uma melhor segmentação de padrões. Esses algoritmos geralmente empregam funções de discriminação linear ignorando as características não lineares de alguns casos em espaços de cores genéricos, como o RGB. Foi demonstrado, no entanto, que o uso de funções de similaridade personalizadas [2] com base em uma métrica não linear orientada [3], tem o potencial de considerar-

melhore a qualidade e a robustez de diferentes tipos de abordagens de segmentação [3, 4, 5, 6].

Mas esse recurso personalizado pode ser considerado uma abordagem amplamente empregável como um algoritmo de segmentação, ou é usado apenas para problemas específicos de nicho? Nesse contexto, o objetivo deste estudo é investigar se a substituição de uma métrica de cor linear por uma não linear orientada, proporciona uma mudança significativa na qualidade dos resultados de segmentação, independentemente da abordagem empregada. Para investigar o impacto dessa mudança, selecionamos três abordagens diferentes: split and merge, crescimento de região variacional e segmentação baseada em gráficos, que podem ser adaptadas a uma métrica não linear orientada. Para validar os resultados do método proposto, nas próximas seções delineamos as metodologias gerais empregadas. Posteriormente, foi estabelecido um experimento estatístico para investigar se há uma melhora significativa da abordagem não linear em relação à sua contraparte original e de outras abordagens adicionais, avaliando seu desempenho geral.

2. Materiais e Métodos

Nesta seção, é apresentada uma breve explicação da metodologia empregada e da seleção das abordagens de segmentação utilizadas. Em seguida, são descritas as alterações feitas para adaptar sua versão não linear e os critérios utilizados para validar as imagens. Na Figura 1 é mostrado um diagrama resumindo a metodologia global utilizada.

A partir da análise das abordagens de segmentação, foi escolhido um conjunto de implementação específica que entendemos, é amplamente aceito e representa adequadamente cada filosofia de segmentação particular: Código de Estrutura de Cores (CSC) [7, 8, 9], Mumford-Shah (MS) [10, 11] e Felzenszwalb e Huttenlocher (FH) [12] [12] representando, respectivamente, divisão e fusão, crescimento de região variacional e Segmentação Baseada em Gráficos. Como métrica de similaridade de cor não linear, empregamos a Distância Polinomial Mahalanobis (PMD) [13] no espaço RGB [14]. Este espaço colorido foi utilizado para demonstrar a robustez da métrica não linear, uma vez que este espaço é regularmente distribuído em

todas as dimensões, e a cor é representada como uma dependência dessas dimensões. Em outras palavras, o espaço de cor RGB não é adequado para representar cores corretamente, como uma variação de gradiente suave quando a norma L_2 é usada para categorizar vetores de cores. Para cada uma dessas implementações (CSC, MS, FH) apresentamos versões modificadas (WCSC, SMS, WFH) que empregam o PMD como sua métrica de similaridade [5, 4, 6].

2.1 Métrica de Cor Não Linear: a Distância de Mahalanobis Polinomial

A Distância mahalanobis (MD) é uma distância estatística usada para calcular a semelhança entre distribuições multivariadas [13]. O MD baseia-se na matriz média e de covariância da distribuição, utilizada como referência e formalmente definida pela equação 1.

$$MD(x,y)=\frac{q}{(x-y)^T A^{-1} (x-y)}, \quad (1)$$

onde $MD(x,y)$ é a Distância Mahalanobis entre dois vetores de cor $x=(r_x, g_x, b_x)$ e $y=(r_y, g_y, b_y)$ no espaço de cor RGB e A é a matriz de covariância da distribuição utilizada como referência, tendo A^{-1} como sua operação de inversão.

Quando a distribuição utilizada como referência apresenta variação em suas dimensões (ou seja, a covariância entre componentes e suas relações RR, RG, RB), a Distância Polinomial Mahalanobis (PMD) pode ser usada para permitir uma melhor discriminação de padrões de imagem selecionados complexos no espaço de cores. O PMD é a combinação polinomial dos vetores de entrada e suas projeções sucessivas a um termo polinomial de ordem superior. Embora o MD seja usado para casos lineares, o PMD permite uma discriminação não linear de dados. Para isso, utilizou-se o quadro apresentado em [14] que otimiza o mapeamento de termos polinomiais eliminando termos não representativos na projeção de ordens superiores (ou seja, Análise de Componentes Principais das variáveis). O PMD pode ser computado através da equação 2:

$$PMD(x,y)=MD_{\sigma^2}(x,y)+\sum_{l=1}^{L-1} MD_{\sigma^2}(qil,qilj). \quad (2)$$

O primeiro termo de pedido $MD_{\sigma^2}(x,y)$ é o MD com menor valor positivo σ^2 usado para evitar limitações de inversão matricial. Isso é necessário especialmente quando $d \ll N$, uma vez que usamos a Decomposição de Valor Singular (SVD) para obter um sistema de

Eigenvalues e vetores, e adicionando um pequeno σ^2 positivo, tornamos invertível novamente. Com $L = 1$ calculamos o MD original. Os seguintes $L > 1$ termos resultados na q-order ($q = 2L^{-1}$). Por exemplo, com $L = 2$ obtemos uma q-ordem de 2, e assim por diante. Os termos compostos por q^{il} e q^{lj} são as próximas projeções ($q+1$) de x e

2.2 Split and Merge: Código de estrutura de cores ponderada

O Código de Estrutura de Cores (CSC) [7, 8] é um método de segmentação de divisão e fusão que constrói uma estrutura hierárquica de ilhas de pixels hexagonais, estruturadas em níveis, a fim de realizar o processo de segmentação. A

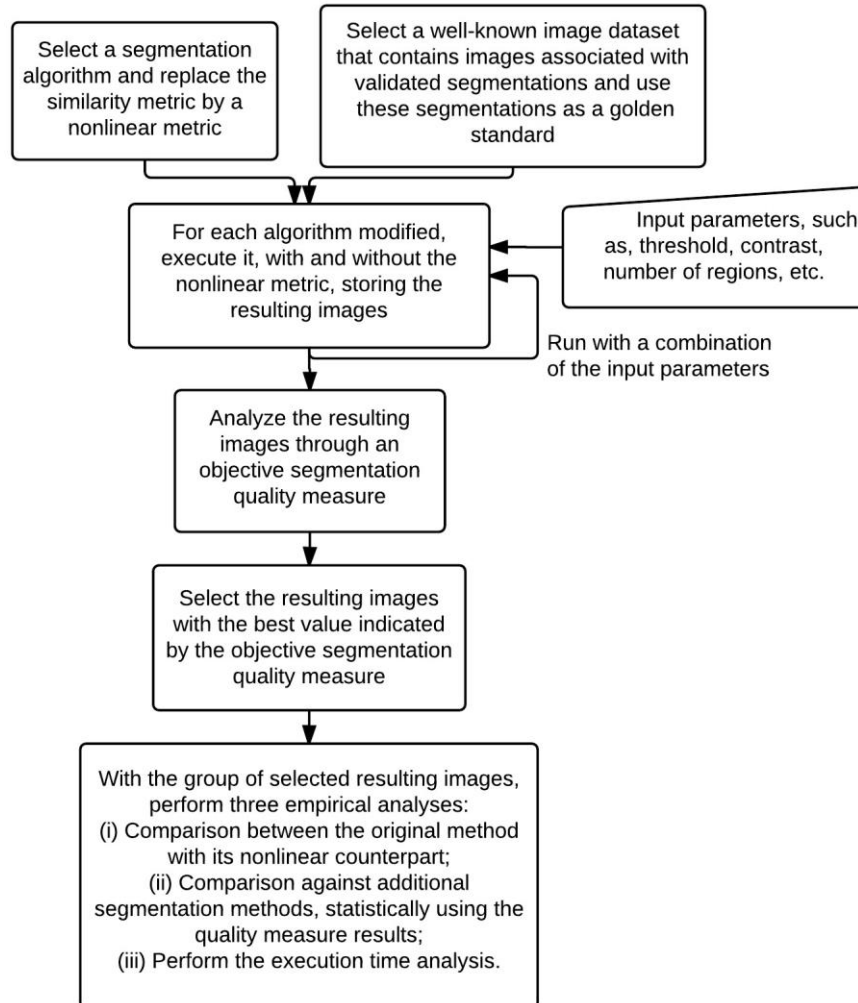


Figura 1. Fluxograma da metodologia utilizada.

y em seus termos polinomiais. Se for necessário mais precisão para discriminar o vetor e eliminar pontos outlier, a ordem de projeção do polinômial pode ser ampliada, aumentando o valor de L , restringindo a área de influência da distribuição utilizada como referência. Curiosamente, se a matriz de covariância é uma matriz de identidade, a métrica é reduzida à norma L_2 , apresentando-se como uma alternativa dupla a uma Distância Euclidiana Não Linear Ponderada.

estrutura hierárquica é uma forma eficiente de manter os resultados parciais, permitindo uma navegação fácil entre níveis distintos. A estrutura hierárquica também permite que o algoritmo mantenha um registro das características locais e globais da imagem. O algoritmo pode ser descrito em quatro etapas: pré-processamento, inicialização, vinculação e divisão. O CSC utiliza um critério de variável local baseado na Distância Euclidiana linear (ED) para o cálculo da similaridade durante a vinculação.

O Código de Estrutura de Cores Ponderadas (WCSC) [5] modifica a medida de similaridade empregada no CSC através da inserção de uma métrica não linear no cálculo da Distância Euclidiana Ponderada (WED). Do ponto de vista

prático, a PMD fornece topologia não linear que é usada para ponderar o WED de tal forma que os valores regulares da norma L_2 são combinados nesta topologia. Maior a ordem polinomial usada para construir os mapas são, mais restritiva o PMD é para o WED. Um exemplo de como a topologia age sobre um domínio discreto e como ela interage com um conjunto de pontos de treinamento é apresentada em [3].

Características importantes do WCSC são os parâmetros limiar (th) e contraste (c). O limiar determina o limite de similaridade para uma região a ser fundida ou não, e pode estar em uma faixa de 0 a $+\infty$. O parâmetro de contraste c , usado apenas no WCSC, determina o quão delimitado o padrão será e pode variar em uma faixa de 0 a $-\infty$.

Todo o processo executado pela função de similaridade não linear é ilustrado na Figura 2. Os parâmetros de entrada para

WCSC são: o padrão P selecionado, os valores de contraste e limiar. Na primeira etapa, calcula-se a Distância Euclidiana (ED) entre as regiões A e B (B é a região a ser testada). Se a distância for menor do que o limiar desejado (th), as duas regiões estão ligadas. Caso contrário, a região B será re-analisada verificando seu WED para um padrão P selecionado pelo PMD. O valor é verificado para ver se é menor do que o th , a fim de re-verificar se as regiões devem estar vinculadas ou não. Em seguida, o processo de segmentação continua.

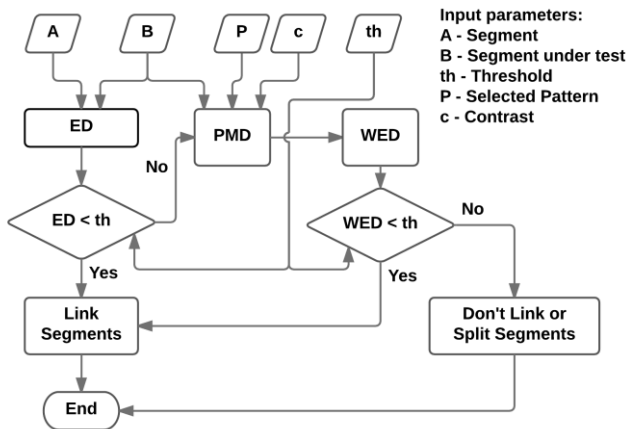


Figura 2. Fluxograma do método WCSC, ilustrando o procedimento utilizado.

2.3 Métodos Variacionais: Mumford Shah Energy Funcional

O Mumford-Shah (MS) [10, 11] é um modelo variacional baseado na minimização de uma energia funcional E . Esta função emprega equações diferenciais parciais para modelar propriedades de um fenômeno (A_1, \dots, A_n) e encontrar funções $u_1(x), \dots, u_n(x)$ que podem efetivamente minimizar a energia, gerada pela soma de cada propriedade particular A_n . Cada propriedade também é chamada de termo da função energética, e a minimização de E é um compromisso entre cada termo. Em nossos experimentos usamos uma versão simplificada desta função de energia [2] também descrita na equação abaixo de 3:

Com

$$E(u, K) = \beta \int (u - I)^2 dx + \lambda'(K) \quad (3)$$

Onde :

- $\beta = \frac{|\Omega_i| \cdot |\Omega_j|}{|\Omega_i| + |\Omega_j|}$, é um coeficiente de área utilizada para proporcionar regularidade ao modelo quando a fusão da região está sendo realizada entre regiões adjacentes $|\Omega_i|$ e $|\Omega_j|$;

- $(u - I)$ é um termo de fidelidade que estima a qualidade da aproximação em termos de peças de uma função $u(x, y)$ para $I(x, y)$;
- λ - é o parâmetro de espaço de escala para granularidade do segmento, usado para controlar sub e sobre segmentação;
- $'(K) = \text{RK} \cdot d'$ é o comprimento da fronteira entre $|\Omega_i|$ e $|\Omega_j|$ no sentido Hausdorff.

A energia de minimização simplificada $E(u, K)$ é dada apenas em função de limites comuns para regiões adjacentes. O coeficiente β pondera a aproximação das regiões por seus valores médios u e i . Seu crescimento exponencial típico faz com que grandes regiões absorvam as pequenas, de acordo com um critério de similaridade predeterminado entre os vetores de cor. O coeficiente *controla* e limita o número total de regiões. Começando com cada pixel na imagem sendo uma única região, o algoritmo sucessivamente mescla quaisquer duas regiões adjacentes Ω_i e Ω_j , o que leva à maior diminuição de energia. A aproximação constante, o ranking de regiões, a fusão de duas regiões de menor energia Ω_i e Ω_j , o recálculo de energia e reordenamento de pilha de regiões, continua até que o número de regiões informadas como parâmetro seja atingido. Mumford-Shah usa a fusão como critério de discriminação para recalculer e recalculer as regiões empilhadas.

Mumford-Shah supervisionado (SMS) é uma variante da equação original de Mumford-Shah, onde uma função de discriminação supervisionada é usada para substituir a aproximação entre regiões adjacentes [2, 4]. Esta variante modifica a fusão e, conseqüentemente, o cálculo de energia e reordenação das regiões que utilizam a métrica não linear, descrita como a seguinte desigualdade 4:

$$\lambda \leq \beta \cdot \frac{\phi}{\ell(K)} \cdot \text{PMD}(u_i, u_j) \quad (4)$$

onde:

- ϕ é a fronteira equivalente entre as regiões Ω_i e Ω_j [4];
- $'(K)$ é o comprimento do limite;
- $\text{PMD}(u_i, u_j)$ é a nova medida de similaridade entre regiões Ω_i e Ω_j .

O fluxo computacional executado pela variante MumfordShah supervisionada é ilustrado na Figura 3. Os parâmetros de entrada do SMS são as regiões a serem agrupadas, o padrão selecionado da imagem e o parâmetro de escala, respectivamente. Inicialmente, os parâmetros de

execução foram determinados a partir das regiões adjacentes de entrada Ω_i e Ω_j . A distância entre as regiões adjacentes Ω_i e Ω_j , que será agrupada, é calculada utilizando-se o valor médio de cada região (u_i e u_j), o mapa topológico M (gerado a partir do padrão selecionado da imagem) e um valor de contraste (c). O próximo passo é o cálculo do termo de regularização da área, ou seja, β também da equação 4. Para isso, a quantidade de pixels que beiram as regiões Ω_i e Ω_j é utilizada. Depois disso, o último termo da função, ϕ , escalar ≥ 0 , é usado para penalizar a equação devido a um método de fronteira de equivalência, obtendo o valor final do Eq. 4. Com base nesse valor, o algoritmo faz a atualização da pilha de segmentos adjacentes e continua esse processo de cálculo e atualização até que a condição de parada seja atingida.

ponderado pela Distância de Mahalanobis Polinomial, mas incluindo as modificações para medidas não lineares. O WCSC testa o limiar *duas* vezes: se ele falhar no ED, a região tem uma segunda chance de vincular o WED. O WFH testa apenas uma vez no WED. Outra modificação foi feita no cálculo do fator de peso pelo PMD. Também considera não apenas a similaridade do nó B em relação ao padrão selecionado, mas também a semelhança do nó A em relação ao mesmo padrão. Essa modificação é realizada a fim de fortalecer a união de nódulos que tenham maior grau de semelhança com o padrão selecionado.

A Figura 4 ilustra o processo realizado pelo WFH. Os parâmetros de entrada para WFH são: regiões A e B, padrão P

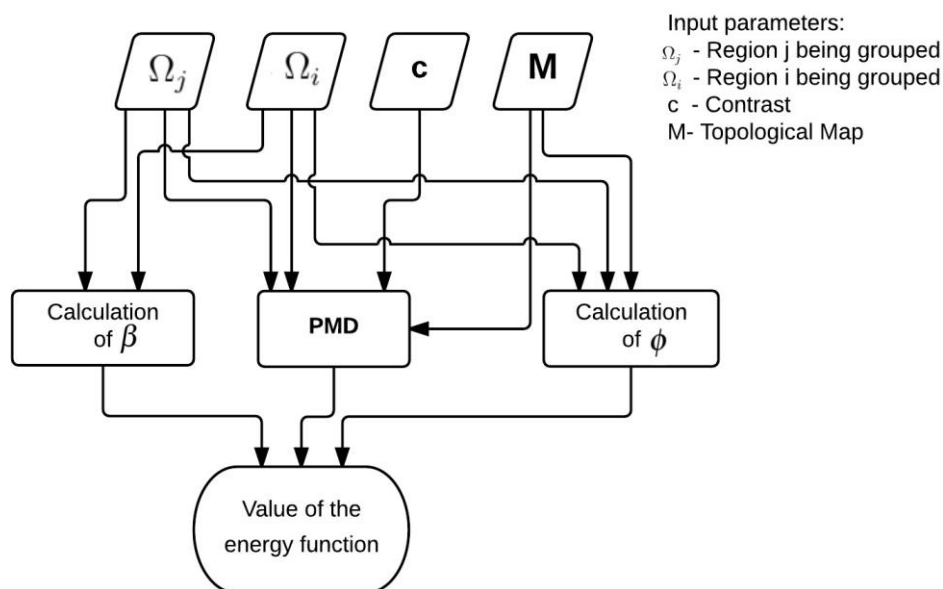


Figura 3. Fluxograma do método SMS, ilustrando funções de similaridade utilizadas.

Segmentação baseada em gráficos 2.4: Método Felzenszwalb e Huttenlocher

O método Felzenszwalb e Huttenlocher (FH) [12] é baseado em uma representação gráfica da imagem como um gráfico não dirigido $G=(V,A)$ onde os nós (ou pixels) $vi \in V$ são conectados por bordas $(vi,vj) \in A$. A segmentação S é a partição de imagem em regiões (ou componentes) $Cn \in S$, onde cada borda tem um peso positivo $w(vi,vj)$ indicando a medida de dissimilaridade entre dois elementos vizinhos conectados por esta borda. Para determinação de dissimilaridade, a FH emprega um predicado que compara as diferenças entre regiões com base no ED dos atributos de cor.

O método Ponderado Felzenszwalb e Huttenlocher (WFH) [6] modifica a construção e o agrupamento das regiões conectadas, substituindo o ED linear por um WED não linear. Da mesma forma que usado no caso WCSC, o WED também é

selecionado e o limiar th . O primeiro passo, é o cálculo do PMD entre o padrão P e os nós A e B separadamente. O segundo passo é o cálculo do WED utilizando os dois resultados obtidos e os nós originais, resultando em um novo peso de dissimilaridade W associado à conexão dos nós A e B . Se o valor de W for menor que o th , então os nós A e B são agrupados na mesma região conectada e o peso da região é ajustado. Caso contrário, os nós são mantidos separados.

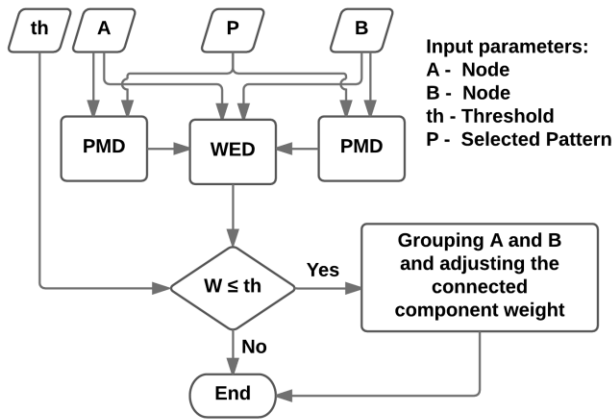


Figura 4. Diagrama de fluxo do método WFH, ilustrando o procedimento utilizado.

É importante notar que o algoritmo FH original emprega uma etapa de pré-processamento antes da segmentação. Os autores utilizaram uma função de suavização σ com um limiar e determinaram um tamanho mínimo de uma região



Figura 5. Efeitos de duas seleções de padrão diferentes usando uma linha branca para segmentação WCSC. Imagem original em (A) com seleção de primeiro padrão resultando em regiões (B). Uma seleção de segundo padrão (C) resultando em regiões (D).

conectada min . Eles originalmente sugeriram os seguintes valores: 0,5, 500 e 20, respectivamente, para σ , th e min . Tivemos que testar esses parâmetros para obter resultados mais significativos. Usando novamente o conjunto de dados de Berkeley, testamos uma combinação de parâmetros encontrando novos valores th e min [6].

2.5 Dados de Avaliação e Métrica

As imagens utilizadas no presente trabalho foram obtidas a partir do conjunto de dados de segmentação de Berkeley e benchmark ¹ [15]. Este conjunto de dados é bem conhecido pela comunidade de processamento de imagens e é usado no presente trabalho como referência de segmentação padrão ouro. Cada imagem de amostra contém várias verdades terrestres (GT) geradas por diferentes observadores humanos e um subconjunto de 60 foram selecionados e usados. Essas

imagens apresentaram alto grau de consenso (ou baixa discordância) em objetos do segmento avaliados manualmente pelos observadores, como pode ser notado na tabela 1 do apêndice A. Devido à racionalização do espaço, algumas imagens foram utilizadas para ilustrar os resultados, mas o conjunto de dados completo pôde ser observado no seguinte endereço: <http://www.incod.ufsc.br/non-linear-color-metrics/>.

Para avaliar os resultados, utilizou-se uma métrica de qualidade automatizada bem estabelecida do Índice rand (RI) [16]. As imagens resultantes foram comparadas com a verdade terrestre de Berkeley (GT), mantendo a mesma estratégia empregada por obras anteriores [3, 8, 5, 6].

3. Resultados Experimentais

Esta seção apresenta os resultados de segmentação para a comparação de abordagem proposta categorizada em três experimentos. O primeiro compara o método não linear com a versão original. Isso será realizado por um teste de hipótese paramétrica no índice Rand, para confirmar se as diferenças

entre os algoritmos são significativas. O segundo experimento compara o índice Rand dos métodos usando a métrica não linear em relação aos métodos de segmentação comumente utilizados. O último experimento compara todos os métodos de tempo médio de execução, com o objetivo de investigar os algoritmos em termos de sua eficiência. É importante ressaltar que o método não linear é uma segmentação orientada a padrões. Essa característica é melhor ilustrada na figura 5, onde para a mesma imagem, a seleção de padrões diferentes resulta em diferentes regiões.

3.1 Experimento 1: Comparação entre as versões linear e não linear

Nesta seção investigamos as diferenças de desempenho entre as versões lineares e não lineares de três algoritmos de segmentação. A comparação Split and Merge entre CSC e WCSC é ilustrada lado a lado na Figura 6. Como pode ser notado pela primeira linha da figura 6, menos regiões foram

¹ As imagens estão disponíveis em: <https://www.eecs.berkeley.edu/Research/Projetos/CS/vision/bsds/>, acessado em: 19/06/2018.

geradas pelo WCSC na estrela e uma melhor coerência de objetos foi alcançada. Este desempenho está diretamente relacionado com a seleção de padrões ilustrada em (B). Quando a seleção mais semelhante é ao padrão alvo, maior é a sua probabilidade de ser fundido na mesma região. Na segunda linha, devido à seleção de fundo como padrão, obtivemos uma melhor coerência nos elementos em primeiro plano. Na terceira fila ambos os algoritmos identificaram duas regiões, mas enquanto o CSC perde a forma do barco, o WCSC o mantém coerente. Na quarta linha, a seleção apresentou variações em termos de distribuição de cores. Neste caso, o WCSC apresentou uma melhor segmentação perceptível do cogumelo, em uma região homogênea, o que destaca o padrão orientado pela inclusão do PMD.

A comparação de crescimento da região variacional entre MS e SMS é ilustrada lado a lado na figura 7. Como é apresentado, a MS por si só apresenta limitações em todas as colunas (C). A primeira fila apresentou algumas regiões mescladas. Na segunda e terceira linhas alguns elementos foram perdidos e na quarta fila alguns sobre segmentação foram notados. Essas limitações foram quase atenuadas nos resultados do SMS, coluna (D). Na primeira linha, a estrela é coerentemente segmentada em um segmento único, eliminando alguns vazamentos inapropriados apresentados anteriormente. Na segunda linha, os mesmos aspectos da segmentação são mitigados e, na terceira e quarta linha, é apresentada uma melhor coerência entre os segmentos, evitando as regiões falidas e reduzindo a sobre segmentação, respectivamente.

A comparação de segmentação baseada em gráficos entre FH e WFH é ilustrada lado a lado na figura 8. Da mesma forma que nas comparações anteriores, pode-se notar que a ESF apresentou problemas em todas as colunas (C) resultados, especialmente sobre segmentação. Os resultados do WFH em todas as linhas aparecem com menos segmentação e mais coerência da região, destacando também a característica de segmentação orientada a padrões.

Foi realizado um teste de hipótese paramétrica para cada caso

para confirmar se as diferenças entre os dois algoritmos, melhoria da versão não linear demonstrada pelo teste de




Figura 6. Comparação entre segmentação CSC e WCSC. Imagem original na coluna (A), linha branca mostrando a seleção de padrões em (B) e os resultados de segmentação de CSC e WCSC em (C) e (D), respectivamente.

lineares e não lineares, são significativas ou apenas causadas por efeitos externos. Utilizou-se as seguintes suposições: O Índice rand x diferenças emparelhadas ($x_{linear} - x_{nonlinear}$) entre os dois métodos foram considerados como ter uma distribuição normal com uma população grande suficiente de $n = 60$ imagens. Estabeleceu-se um teste de hipótese unilateral com nível de significância de $\alpha = 5\%$, com hipótese nula indicando que algoritmos têm desempenho semelhante e hipótese alternativa indicando que o algoritmo proposto mostra um desempenho significativamente melhor (menor diferença entre segmentação e GT). Durante a análise, a rejeição da hipótese nula para todos os casos investigados, indicou com 95% de confiança que as versões não lineares apresentaram melhora significativa no desempenho. A Tabela 1 descreveu todos os parâmetros determinados na análise e a figura 9 ilustram os gráficos de enredo obtidos no primeiro experimento. A partir desse número é possível observar a

hipótese nos seguintes parâmetros. Redução do Índice rand e parâmetros de variância, o que indicou um comportamento de segmentação mais estável para as três abordagens testadas. Em [17], apresentamos uma descrição detalhada do cálculo do índice Rand para cada caso.

3.2 Experimento 2: Comparação mais ampla com outros métodos de segmentação

Nesta seção descrevemos a comparação de dados entre as abordagens lineares e não lineares anteriores em relação aos 8 métodos adicionais de segmentação comumente utilizados usando o Índice Rand, contra um GT. Os 8 algoritmos de segmentação adicionados são: Detecção de borda e segmentação de imagem (EDISON) [19], Mumford-Shah (MS) [10], Bacia Hidrográfica (WS) [20], JSEG [21], Recursivo

Segmentação Hierárquica (RHSEG) [22], Rede gradiente Método (GNM e GNM2) combinado com MS e CSC [8]. O gráfico da figura 10 mostra valores do índice rand para as imagens na figura 12 para cada algoritmo testado. De acordo com o gráfico, as versões não lineares estão entre os

Foram realizados testes adicionais para estender a análise a um grupo de 16 imagens selecionadas do conjunto com 60 imagens previamente construídas. Cada Índice Rand resultou da comparação de segmentação com a imagem GT, foi agrupado pelo método e ilustrado na figura 11. Nesta figura,




Figura 7. Comparação entre segmentação de MS e SMS. Imagem original na coluna (A), linha branca mostrando a seleção de padrão em (B) e os resultados de MS e SMS em (C) e (D), respectivamente.

menores valores do Índice Rand, indicando maior semelhança e menor variância de dados.

A Figura 12 mostra a segmentação da 368078 de imagem para cada método utilizado. Como se observa neste número, a segmentação RHSEG apresentou regiões agrupadas incorretamente. Este resultado de segmentação está de acordo com o valor do índice Rand, conforme mostrado na figura 10. Por outro lado, observando os resultados obtidos pela EDISON, um pequeno número de regiões foram geradas e há maior coerência entre os objetos que formam a imagem. Portanto, EDISON apresentou o menor valor do índice Rand, conforme mostrado na figura 10.

métodos com menores valores do Índice rand, menor variância e sem outliers são os que têm um comportamento de segmentação mais estável, o que pode ser notado nos três métodos associados à métrica não linear.

3.3 Experimento 3: Comparação de métodos baseados no tempo de execução

Nesta seção comparamos os tempos médios de execução de cada método de segmentação com e sem a melhoria proposta, para avaliar os algoritmos em termos de eficiência. Para esta análise, os tempos de execução dos métodos foram registrados executando os algoritmos em

uma CPU Core 2 Duo P8700 2.53GHz no Ubuntu Linux para todas as 60 imagens selecionadas usadas no primeiro experimento. Os valores individuais obtidos podem ser observados na página web descrevendo nossos

experimentos e o relatório técnico [17]. O tempo médio de execução obtido pelo experimento para todas as 60 imagens é ilustrado em



Figura 8. Comparação entre segmentação FH e WFH. Imagem original na coluna (A), uma linha branca mostrando a seleção de padrão em (B) e os resultados de FH e WFH em (C) e (D). respectivamente.

figura 13.

4. Discussão

Analisando os tempos médios de execução, pode-se notar que

Todo estudo tem necessariamente limitações e impõe trocas.

métodos que empregam distância de Mahalanobis Polinomial (PMD)

Discutimos aqui se nosso método poderia representar uma ameaça a um

têm maiores tempos de execução. Isso se justifica pela introdução de uma validade mais geral das conclusões alcançadas neste trabalho.

tion dos cálculos extras do PMD com a similaridade

A primeira ameaça identificada foi o menor número de algoritmos

cálculo (treinamento e avaliação). No entanto, apesar disso escolhido para ser testado dentro de nossa abordagem. Com o objetivo de

O uso de uma métrica de cores não linear pode melhorar sistematicamente a segmentação?

aumentar no tempo de execução, podemos observar um ganho em verificar a influência de uma métrica não linear como um dispositivo central em termos de eficácia como mostrado pelos experimentos anteriores. Para algoritmos de segmentação, procurando um geral A Tabela 2 dá um resumo sobre a comparação entre a melhoria dos resultados de segmentação, selecionamos três algoritmos de corte e eficácia. Nesta tabela podemos destacar algoritmos (CSC, MS e FH). Esses algoritmos foram selecionados que, embora o tempo de execução de todos os métodos não lineares tem porque este dispositivo central é de alguma forma dissociado aumento dos resultados foram melhorados, demonstrados pelo de seu conceito principal, e uma métrica de distância pode ser facilmente menores valores médios e de desvio padrão quando comparados incluídos para conduzir esses algoritmos. Por outro lado, há contra seus homólogos lineares.

são algoritmos onde este "dispositivo" não é completamente claro e outras dependências podem ser encontradas, tornando difícil ou imprecisa a adição de uma métrica não linear. Por isso, adotamos uma estratégia para utilizar algoritmos de segmentação estáveis, onde a Tabela 1. Parâmetros obtidos durante o experimento de teste de hipóteses. Onde s_{linear} e $s_{nonlinear}$ são o desvio padrão para os algoritmos com abordagens lineares não lineares, respectivamente, e $z_c = 1.65$ é o valor crítico obtido da tabela estatística de [18] para um valor acumulado = 0.950529.

Parâmetro de diferenças	CSC/WCSC	MS/SMS	FH/WFH
Significar $xdiff = x_{linear} - x_{nonlinear}$	0.0285	0.1099	0.02930
Desvio padrão s $s_{2linears2nonlinear} = \frac{xdiff}{n}$	0.0149	0.0186	0.01749
Valor z normalizado $z_{diff} = \frac{xdiff}{s_{diff}}$	1.9127	5.9086	1.6752
Zc de valor z crítico =	1.65	1.65	1.65

Mesa 2. Tabela mostrando o tempo de execução dos métodos e seu valor médio de índice rand para todas as 60 imagens.

Método	Tempo médio de execução (ms)	Valor médio do Rand	Desvio padrão de valor de rand
CSC	112.287	0.1514	0.0893
WCSC	4616.29	0.1229	0.0742
MS	28970.40	0.2129	0.1228
SMS	169411.39	0.1030	0.0756
FH	123.12	0.1464	0.1082
TELETRABALHO	15599.90	0.1171	0.0815




Figura 9. Gráficos de plot de caixa comparando análise estatística de todos os dados para CSC, WCSC, MS, SMS, FH e WFH para todas as 60 imagens selecionadas.

adição de uma métrica não linear pode ser facilmente realizada sem afetar outras partes do método comparado. Por uma questão de completude, fornecemos, no Experimento 2, uma comparação de nossos resultados com um segundo conjunto de outros algoritmos de segmentação comuns em suas versões originais, ou seja, não estendemos esses algoritmos com espaços de cores não lineares.

A segunda ameaça foi o uso de apenas um subconjunto de conjunto de dados de Berkeley. Nossa seleção de subconjuntos de conjunto de dados de Berkeley, contendo apenas "GTs de consenso", pode parecer subjetiva, mas nossa seleção de critérios foi simples: as 60 imagens apresentando GT's com a menor variação entre os sujeitos. Fizemos isso para evitar a introdução de ruído extra devido à divergência entre os diferentes GTs da mesma imagem. O subconjunto resultante ainda representa uma grande variedade de imagens ao ar livre e um n estatisticamente significativo.

Outra possível ameaça foi o emprego apenas do Índice Rand como abordagem de validação. A escolha do Índice Rand como único método para a análise automatizada da qualidade dos resultados foi baseada em experimentos passados [4, 8], onde outros métodos de análise GT também foram utilizados. Durante esses experimentos, os resultados obtidos com o uso de Rand foram os mais semelhantes à análise subjetiva humana ao tratar segmentações de GT-desviantes, em comparação com outros métodos conhecidos como Fowlkes-Mallows [23], Jacard [24], BGM [25] e Dongen [26]. O BGM, por exemplo, tende a se sobreter em segmentações, dando notas altas falsas aos resultados com vazamento de região.

Também uma possível ameaça foi a nossa escolha de não usar outros espaços de cores genéricos e também espaços de cores lineares personalizados. Nossa intenção com este trabalho era fornecer uma primeira análise em um contexto mais amplo, não limitado a uma categoria homogênea de imagens e não se limitando a um tipo de algoritmo, da questão se espaços de cores não lineares e personalizados são geralmente uma escolha melhor do que simples espaços de cores lineares. Há uma grande paleta de espaços de cores lineares de uso geral, que vão desde o simples HSV até escolhas elaboradas como o CIELab, que não levamos em consideração neste estudo. Há, no entanto, evidências na literatura (por exemplo[27]) de que, mesmo

lineares, do outro lado, foram deixados de fora porque evidências coletadas em um estudo anterior [3] mostraram que, pelo menos para a Distância mahalanobis (MD), produzir uma métrica linear personalizada envolve o mesmo esforço de seleção de amostras para uma determinada categoria de imagem do que para uma métrica não linear, mas a versão não linear da métrica personalizada produz resultados muito melhores.

A última ameaça identificada foi no uso de espaços de cores aprendidos personalizados os algoritmos de segmentação devem sempre funcionar melhor porque o espaço de cores é específico para uma determinada imagem

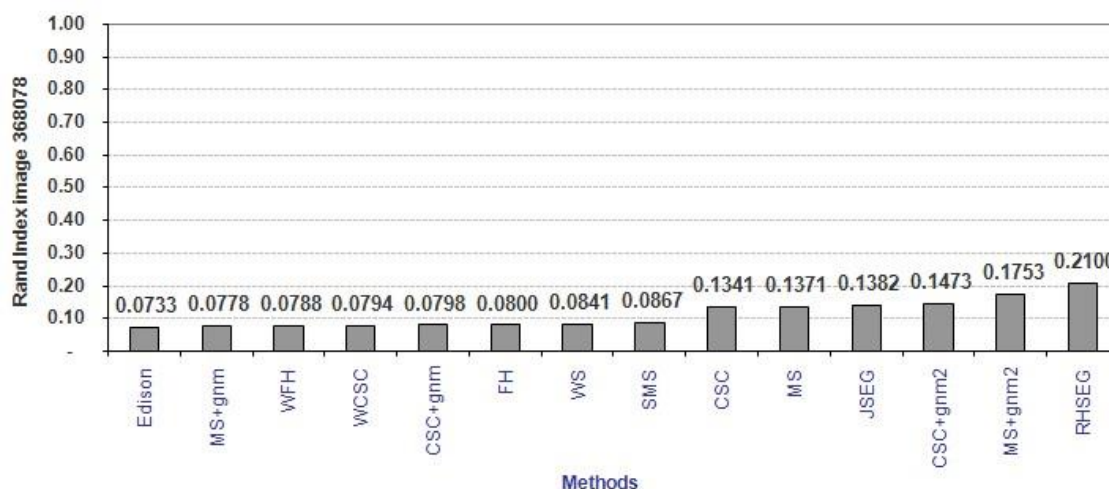


Figura 10. Gráfico mostrando a pontuação do índice Rand para a imagem 368068 para cada método testado.




Figura 11. Comparação entre todos os métodos testados com base no valor do índice Rand.

que alguns espaços de cores genéricos sejam melhores para categorias específicas de imagens, em geral, não há diferenças significativas quando comparadas em um contexto mais amplo. Espaços de cores personalizados

e não tem caráter geral. Além disso, tal espaço de cor caracterizaria essa abordagem como uma segmentação semi-supervisionada, o que não é comparável a uma segmentação não supervisionada empregando espaços de

cores genéricos. Isso seria verdade se um determinado espaço de cores pudesse ser usado para apenas uma imagem. Dentro de um determinado contexto, no entanto, uma função de similaridade personalizada gerada a partir de um padrão obtido a partir de apenas algumas imagens de amostra de uma categoria pode de fato ser generalizada para toda a categoria de imagens, como mostrado anteriormente para a categoria de "imagens de cavalos ao ar livre" [2] e também foi mostrado para a categoria de problemas "navegação robô em um ambiente florestal" em [14], especialmente porque é possível direcionar as características de cor dos objetos de interesse que comumente aparecem em uma determinada categoria de imagens. Isso significa que uma função de similaridade personalizada gerada, por exemplo, para "cenários de tráfego de rodovias" provavelmente seria inútil para a segmentação de "arte pontilista", mas provavelmente funcionará melhor para cenários de navegação de carros do que um espaço de cores lineares genéricos como o RGB. Essa suposição, no entanto, ainda precisa ser melhor apoiada por resultados mais experimentais.

5. Conclusão e trabalho futuro

O objetivo deste estudo foi analisar se o uso de métrica de cores personalizadas e não lineares pode sistematicamente

provar o desempenho dos algoritmos de segmentação, independentemente de qual tipo de algoritmo de segmentação é empregado. Para demonstrar o potencial dessa abordagem, foram realizados três experimentos em imagens do conjunto de dados de Berkeley, utilizando o índice Rand como medida objetiva de qualidade de segmentação para a validação automatizada dos resultados de segmentação. Os resultados obtidos mostram, para esses experimentos, uma diminuição do índice de diferença quando uma função de discriminação não linear é utilizada para a condução do processo de segmentação.

No primeiro experimento, demonstramos estatisticamente o potencial de melhoria de nossa abordagem com a comparação entre os algoritmos selecionados versão original com sua contraparte não linear. No segundo experimento, posicionamos os métodos associados à métrica não linear em um ambiente de experimento com alguns algoritmos de segmentação comumente usados. Neste experimento, mostramos que os métodos com a abordagem personalizada produziram




Figura 12. Comparação visual dos resultados obtidos pelos métodos testados para a imagem 368078. (A) imagem original, (B) Ground Truth, (C) Edison, (D) MS+GNM, (E) WFH, (F) WCSC, (G) CSC+GNM, (H) FH, (I) WS, (J) SMS, (K) CSC, (L) MS, (M) JSEG, (N) CSC+GNM2, (O) MS+GNM2, (P) RHSEG.

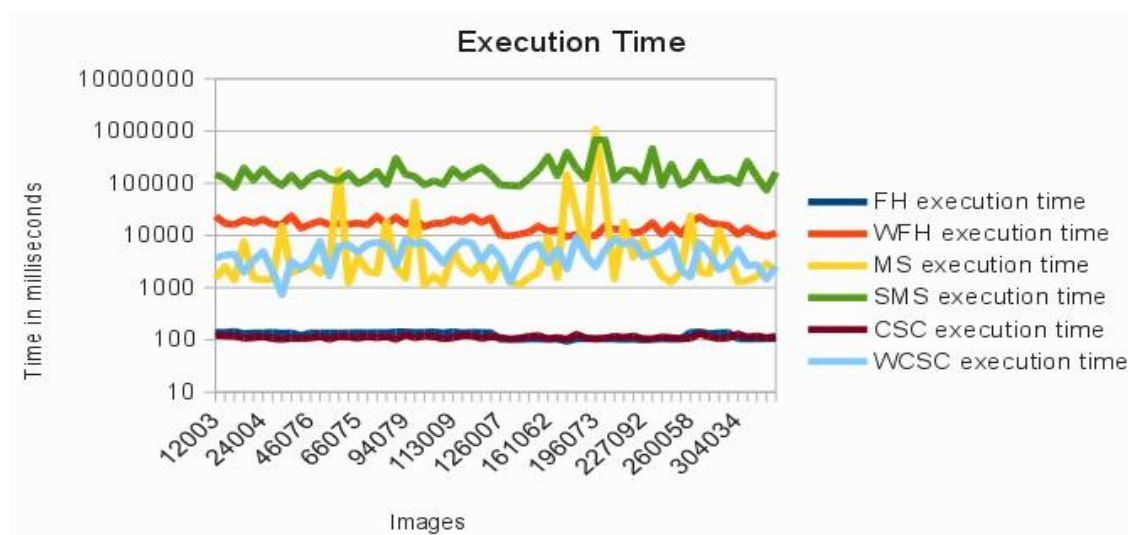


Figura 13. Gráfico ilustrando o tempo de execução dos algoritmos em uma escala logarítmica.

resultados com menos outliers e variância em comparação com as outras abordagens. No último experimento, comparamos os algoritmos de segmentação com base em seu tempo de execução, onde mostramos que a métrica não linear aumenta o tempo de execução, tornando evidente a troca entre eficácia e eficiência.

Mesmo que este estudo seja apenas um primeiro passo em uma série de possíveis estudos de avaliação empírica empregando outros métodos de segmentação e diferentes métricas de distância não lineares, mostrou fortes evidências de que, pelo menos para algumas classes de imagens, o uso de uma métrica personalizada de espaço de cor não linear pode ser considerado como uma melhoria aplicável para fins gerais.

5.1 Obras futuras

Apesar dos resultados promissores obtidos com a análise e validação do método desenvolvido, ainda há melhorias a serem feitas para alcançar resultados mais consistentes. Algumas dessas melhorias são:

- Uma desvantagem resultante da introdução da Distância Polinomial mahalanobis (PMD) é o aumento do tempo de execução. Para resolver esse problema, uma implementação *utilizando a Unidade de Processamento gráfico (GPGPU)* poderia ser realizada.
- Visando a melhoria dos resultados apresentados pelos métodos de segmentação devido à adição do PMD como métrica, ainda há possibilidades de otimização dos parâmetros de entrada, encontrando os valores ideais para limiar e contraste e realizando uma análise mais profunda do padrão de entrada selecionado.

- Outro campo de estudo é a possibilidade de adicionar informações extras, por exemplo, textura, à métrica de similaridade, que é facilitado pelo uso do PMD, uma vez que o PMD pode analisar a semelhança entre distribuições em um espaço ndimensional, incluindo parâmetros descrevendo atributos de textura [14].
- Mais experimentos podem ser realizados estendendo as versões originais dos algoritmos empregados no experimento 2 e empregando conjuntos de dados associados ao GT de imagens de diferentes tipos, não apenas as cenas ao ar livre do conjunto de dados de Berkeley. Além disso, diferentes espaços de cores seriam experimentados nos experimentos posteriores.

6. Contribuições autorais

- Carvalho, L.E. - Pesquisador que desenvolveu dois dos principais métodos avaliados no manuscrito e escreveu o artigo.
- Mantelli Neto, S. L - Pesquisador que ajudou no processo de escrita e realizou a análise estatística.
- Sobieranski, A.C. - Pesquisador que desenvolveu o outro método principal avaliado no manuscrito e ajudou no processo de escrita.
- Comunello, E. - Pesquisador que realizou uma revisão mais geral.
- von Wangenheim, A - Conselheiro que ajudou no processo de escrita e também realizou uma revisão geral.

Referências

- [1] UDUPA, J. K. et al. Uma estrutura para avaliar algoritmos de segmentação de imagens. In: *Imagens Médicas Informatizadas e Gráficos*. Nova Iorque, Estados Unidos: Pergamon Press, 2006. v. 30. [2] SOBIERANSKI, A.C. et al. Aprendendo uma métrica de distância de cores para segmentação de imagens baseada na região. *Padrão Recognit. Lett.*, v. 30, n. 16, p. 1496-1506, 2009.
- [3] SOBIERANSKI, A. et al. Aprendendo uma métrica de distância de cor não linear para a identificação de coloração imunohistoquímica da pele. Em: *Baseado em computador Sistemas Médicos, 2009. CBMS 2009. 22ª IEEE Simpósio Internacional em diante*. Albuquerque, EUA: IEEE, 2009. v. 22.
- [4] SOBIERANSKI, A.C.; COMUNELLO, E.; WANGENHEIM, A. von. Aprendendo uma métrica de distância não linear para segmentação de imagens supervisionada de fusão de regiões. *Computação. Vis. Imagem Underst.*, v. 115, n. 2, p. 127-139, 2011.
- [5] CARVALHO, L. E. et al. Método de segmentação de cores híbridas usando uma função de similaridade não linear personalizada. *Int. J. Image Graph.*, v. 14, n. 01n02, p. 1-13, 2014.
- [6] CARVALHO, L. E. et al. Melhorando a segmentação de imagens baseada em gráficos usando métricas de similaridade de cores não lineares. *Int. J. Image Graph.*, v. 15, n. 04, p. 361-369, 2015.
- [7] REHRMANN, V.; PRIESE, L. Segmentação rápida e robusta de cenas de cores naturais. In: PONG, R.C.-C. (Ed.). *Procedimentos da 3ª Conferência Asiática sobre Visão Computacional*. Hong Kong, China: [s.n.], 1998. (LNCS, v. 1351), p. 598-606.
- [8] WANGENHEIM, A.; BERTOLDI, R.; ABDALA, D. a. Segmentação de imagem de cor usando um método de rede gradiente aprimorado. *Padrão Recognit. Lett.*, v. 30, n. 15, p. 1404-1412, 2009.
- [9] PRIESE, L.; STURM, P. *Código de estrutura de cores*. Acessado em 26 de agosto de 2014. Disponível em: <http://www.uni-koblenz.de/~lb/lb/downloadi>.
- [10] MUMFORD, D.; SHAH, J. Detecção de limite minimizando as funcionalidades. In: *Conferência IEEE sobre Visão computacional e Reconhecimento de Padrões*. Vancouver, Canadá: IEEE, 1985. v. 2.
- [11] MUMFORD, D.; SHAH, J. Aproximações ideais por funções suaves e problemas de variação associados. *Comm. Pure Appl. Math.*, Wiley Subscription Services, Inc., A Wiley Company, v. 42, n. 5, p. 577-685, jul 1989.
- [12] FELZENSZWALB, P.F.; HUTTENLOCHER
- Segmentação de imagem baseada em gráficos eficientes. *Int. J. Comput. Visão*, v. 59, n. 2, p. 167-181, 2004.
- [13] MAHALANOBIS, P.C. Na distância generalizada nas estatísticas. In: *Proceedings National Institute of Science, Índia*. New Delhi: Instituto Nacional de Ciências, 1936. v. 2.
- [14] GRUDIC, G. Rotulagem de caminho ao ar livre usando distância de mahalanobis polinomial. In: *em Proceedings of Robotics: Science and Systems*. Pensilvânia, EUA: Universidade da Pensilvânia, 2006. v. 1.
- [15] MARTIN, D. et al. Um banco de dados de humanos segmentados imagens naturais e sua aplicação para avaliar algoritmos de segmentação e medir estatísticas ecológicas. In: *Proc. 8th*. Vancouver, Canadá: IEEE, 2001. v. 2.
- [16] RAND, W.M. Critérios objetivos para a avaliação de métodos de agrupamento. *J. Am. Stat. Assoc.*, v. 66, n. 336, p. 846-850, 1971.
- [17] CARVALHO, L. E. et al. *Aplicação de métrica não linear em algoritmos de segmentação*. [S.l.], 2014.
- [18] MONTGOMERY, D.C.; RUNGER, G.C. *Aplicado Estatísticas e Probabilidade para Engenheiros*. 6. ed. Hoboken, Estados Unidos: John Wiley & Sons Inc, 2013. v. 1.
- [19] CHRISTOUDIAS, C.; GEORGESCU, B.; MEER, P. Sinergismo em visão de baixo nível. In: *Reconhecimento de Padrões, 2002. Procedimento. 16ª Conferência Internacional em*. Washington, DC, EUA: IEEE, 2002. (ICPR '02, v. 4).
- [20] VINCENT, L.; SOILLE, P. Bacias hidrográficas em espaços digitais: Um algoritmo eficiente baseado em simulações de imersão. *IEEE Trans. Pattern Anal. Mach. Intell.*, v. 13, n. 6, p. 735-744, 1991.
- [21] DENG, Y.; MANJUNATH, B. Sem supervisão segmentação de regiões de textura de cor em imagens e vídeo. *IEEE Trans. Padrão Anal. Máquina Intell.*, v. 23, n. 8, p. 800-810, 2001.
- [22] TILTON, J. D-dimensional e implementação de segmentação hierárquica recursiva. *IEEE Trans. Padrão Anal. Máquina Intell.*, v. 24, n. 5, p. 603-619, 2002.
- [23] FOWLKES, E.B.; MALLOWS, C.L. Um método para comparando dois agrupamentos hierárquicos. *J. Am. Stat. Assoc.*, v. 78, n. 383, p. 553-569, 1983.
- [24] BEN-HUR, A.; ELISSEEFF, A.; GUYON, EU. Um método baseado em estabilidade para descobrir estrutura em dados agrupados. *Pac Symp Biocomput.*, v. 1, n. 1, p. 6-17, 2002.

[25] JIANG, X.; MARTI, C.; IRNIGER, C. a. Medidas de distância para avaliação de segmentação de imagens. *Eurasip J. Appl. Processo de sinal.*, v. 2006, n. 1, p. 209-209, 2006.

[26] DONGEN, S. *Critérios de desempenho para clustering gráfico e experimentos de cluster markov*. Amsterdã, Holanda, 2000.

[27] WANG, X. et al. Comparação de diferentes espaços de cores para segmentação de imagem usando corte gráfico. In: BRAZ, J. (Ed.). *VISAPP 2014 - Conferência Internacional sobre Visão computacional - Teoria e Aplicações*. Lisboa, Portugal: IEEE, 2014. v. 3.

Apêndice

Mesa 1. Tabela mostrando o número de imagem de Berkeley, o número de regiões atribuídas para cada observador (Obs), a Média e o Desvio Padrão (STDEV) determinou para todas as 60 imagens usadas no presente trabalho.

Imagem	Obs1	Obs2	Obs3	Obs4	Obs5	Obs6	Obs7	Obs8	Significar	STDEV
2092	17	10	19	9	24	7	21		15.2857	6.6008
3096	3	11	6	6	6				6.4	2.8809
12003	6	6	98	6	7				24.6	41.0341
15088	20	15	23	12	17				17.4	4.2778
16052	8	6	4	2	5	10			5.8333	2.8577
22090	86	19	22	36	33	14			35	26.3514
24004	4	10	5	40	36				19	17.5499
24063	16	6	40	15	51				25.6	18.9815
35070	11	12	9	9	10				10.2	1.3038
46076	11	17	80	14	7				25.8	30.5237
48055	16	22	12	5	28	11			15.6667	8.2623
60079	3	3	31	5	4				9.2	12.2147
61060	12	10	6	6	20				10.8	5.7619
62096	17	17	28	13	11	13	9	30	17.25	7.7597
66075	4	8	17	7	7				8.6	4.9295
67079	6	9	39	11	51				23.2	20.4254
68077	14	10	12	14	24	32			17.6667	8.5244
69015	35	13	45	47	39	29	14		31.7142	13.8168
80099	2	2	2	4	6				3.2	1.7888
94079	8	6	2	6	11				6.6	3.2863
97017	15	12	26	11	18	34			19.3333	8.9814

97033	13	32	22	24	25				23.2	6.8337
100075	18	5	13	16	30	16			16.3333	8.1158
100080	7	35	4	27	12				17	13.3977
113009	13	61	41	26	14				31	20.2361
113016	3	31	7	11	24	13			14.8333	10.6285
113044	10	15	5	9	17	6			10.3333	4.8027
118035	14	19	47	12	21				22.6	14.1173
124084	5	49	9	11	46				24	21.5870
126007	21	31	32	17	24	7	18		21.4285	8.6575
135069	6	7	4	4	7				5.6	1.5165
143090	8	11	12	19	17				13.4	4.5055
151087	62	27	43	35	55				44.4	14.2758
159091	10	15	12	11	6	9			10,5	3.0166
161062	19	13	18	13	27				18	5.7445
163014	18	16	16	27	21	17			19.1667	4.2622
167062	5	28	6	8	5	5			9.5	9.1378
167083	5	7	8	7	6				6.6	1.1401
183055	7	52	7	7	18				18.2	19.4858
196073	8	7	2	2	12				6.2	4.2661
207056	4	4	5	5	10				5.6	2.5099
208001	37	19	84	57	25				44.4	26.4726
216053	15	20	36	61	25				31.4	18.2838
225017	12	10	9	11	9				10.2	1.3038
227092	8	62	10	13	10				20.6	23.2120
238011	12	12	5	15	14	12			11.6667	3.5023
247085	6	32	7	53	40	20			26.3333	18.7474

Continuada na próxima página

Tabela 1 – continuada a partir da página anterior

Imagem	Obs1	Obs2	Obs3	Obs4	Obs5	Obs6	Obs7	Obs8	Significar	STDEV
--------	------	------	------	------	------	------	------	------	------------	-------

O uso de uma métrica de cores não linear pode melhorar sistematicamente a segmentação?

249061	8	14	16	10	25				14.6	6.6181
253036	31	37	31	50	37	37			37.1667	6.9402
260058	19	21	7	10	9				13.2	6.3403
291000	11	9	4	7	10	4			7.5	3.0166
295087	7	12	9	33	10	18	15		14.8571	8.8209
299091	4	5	3	11	11				6.8	3.8987
300091	7	8	11	6	20				10.4	5.6833
304034	3	7	6	10	12				7.6	3.5071
310007	14	13	8	9	9				10.6	2.7018
368078	12	7	43	14	35	31	34		25.1428	13.8735
374067	22	12	11	17	10				14.4	5.0299
388016	61	6	19	35	54	110			47.5	36.9364